

# Algoritmo de identificación de etiquetas en botellas de vino

Santiago F. Maudet<sup>1</sup>, Andrés L. Di Donato<sup>1</sup>, Alfredo N. Campos<sup>1</sup>

Universidad Tecnológica Nacional, Facultad Regional Buenos Aires, Laboratorio de  
Procesamiento Digital, DPLab  
dplab@electron.frba.utn.edu.ar,  
<http://www.electron.frba.utn.edu.ar/dplab>

**Abstract.** Los conceptos de visión artificial abarcan simples detecciones de color y forma, hasta complejos algoritmos que detectan e identifican objetos en ambientes adversos. En este trabajo se presentan los resultados concatenar seis algoritmos para detección e identificación de etiquetas de vino en estanterías. Se presentan la especificidad y sensibilidad del algoritmo.

**Keywords:** Visión Artificial - Reconocimiento de Patrones - *Speeded-Up Robust Features*.

## 1 Introducción

En las últimas décadas, investigaciones relacionadas con procesamiento de imágenes se centraron en el desarrollo de técnicas de visión artificial [1,2]. Gracias al advenimiento de algoritmos más eficientes y al mayor poder computacional, éstas se emplean cada vez más en áreas como, entretenimiento, robótica, medicina, e industria [3,4,5,6,7].

Para implementar algoritmos de visión artificial se utilizan métodos comprendidos entre básicas segmentaciones de color, clasificación de objetos, comparaciones, correlaciones, hasta algoritmos más complejos como, redes neuronales y algoritmos genéticos. Técnicas como, segmentación e identificación de objetos por color o forma son utilizadas cuando se desea detectar objetos sencillos, donde no existe demasiada diversidad de colores en la imagen y el entorno es controlado. Éstas requieren tiempo de implementación acotados y según el caso, bajo costo computacional. En cambio, si se desea realizar una detección e identificación en imágenes cuyo entorno y objeto son complejos, los métodos mencionados anteriormente resultan insuficientes [8]. Este tipo de metodologías más avanzadas conllevan a un costo computacional y tiempo de desarrollo mayor.

Existen aplicaciones de visión artificial en control de stock y de calidad referidas a procesos productivos. Las ventajas que proveen son: automatización, ejecución en tiempo real, técnicas no invasivas y de simple implementación referidas a equipamiento [9][10][11][12].

En este trabajo se presenta un algoritmo de detección e identificación de etiquetas de botellas de vino, cuyo objetivo es el cálculo del *facing share* de las estanterías de supermercado. Este indicador representa el espacio ocupado por una marca de vino en el espacio total de la estantería. Este cálculo es relevante para los proveedores de productos ya que se pretende validar si el espacio de muestra en estantería corresponde con lo acordado. Este algoritmo será utilizado por el repositor, el cual toma una foto de la estantería utilizando un smartphone, esa imagen se envía a un servidor, se analiza con el algoritmo y se envía el resultado al repositor, indicando si la cantidad de botellas colocadas corresponde con el *facing share* comprometido. Para la detección se utilizan filtros por color, relación de aspecto y correlación. Finalmente para la identificación se emplea el algoritmo SURF (*Speeded-Up Robust Features*).

## 2 Materiales Y Metodología

### 2.1 Materiales

Las imágenes utilizadas en este trabajo se obtuvieron con una cámara Sony Cyber-shot Modelo DSCW610 de 14.1 MP y un celular Samsung Galaxy Note 3, cámara de 13MP, con resolución 4320x3240 píxeles y 4128x3096 píxeles respectivamente. Ambas en formato color RGB de 8 bits por canal. La imagen a utilizar no debe tener brillo saturado y el contraste debe permitir apreciar los detalles de las etiquetas (Fig. 1). La distancia cámara / objeto se estableció entre 0,5 metros hasta 1 metro. En cuanto a la inclinación de la cámara respecto de las botellas se consideró una dirección de -45 a 45 grados en YZ y -45 a 45 en XY.

Los botellas de vino utilizadas como patrón fueron las siguientes: Dadá, Marcus, Norton Bonarda, Norton Clásico 2011, San Huberto y Santa Ana. Cada patrón fue comparado con un set de 138 imágenes.



**Fig. 1.** Imagen de Estante Original

## 2.2 Metodología

El procedimiento de detección, identificación y conteo de las etiquetas de vino se implementó siguiendo una secuencia de seis etapas. En primera instancia se realizó una segmentación de la imagen original según los estantes presentes en la misma. Luego, se procedió a detectar los sectores blancos en las imágenes obtenidas. Éstos fueron catalogados como candidatos. Éste criterio evitó analizar la imagen completa en etapas posteriores. Las metodologías citadas a continuación se aplican a cada objeto obtenido.

**Obtención de Patrones** El patrón es una imagen donde solo está presente la etiqueta de vino. Para obtener dicha imagen se tomó la fotografía de la botella en solitario a una distancia e inclinación cámara / objeto que no supere los rangos establecidos en las secciones anteriores. Luego se utilizó el algoritmo para detectar el sector perteneciente a la etiqueta, extraerla y almacenarla como patrón (Fig. 2).



**Fig. 2.** Imagen Patrón : Norton Bonarda

**Detección de estanterías** Una vez obtenida la imagen original se procede a segmentar la misma en una cantidad de imágenes que concuerda con el número de estantes presentes. Este procedimiento fue realizado utilizando detección de bordes y transformada de Hough. Esta metodología permite obtener las coordenadas de las rectas horizontales correspondientes a los límites de los estantes. Esto se realizó para acotar el sector de análisis en etapas posteriores.

**Detección de etiquetas** Una vez finalizada la etapa anterior se detectan los objetos candidatos en cada una de las imágenes segmentadas. Esto se realiza implementando un filtro por color (Este trabajo sólo contempla la detección de etiquetas con fondo blanco).

Los sectores blancos cuya área no supera los 10000 píxeles (empírico) no son considerados. Luego se procede a catalogar e identificar cada uno de los objetos presentes utilizando características como, área, perímetro, centro de masa y contornos.

**Identificación de etiquetas** Para realizar la identificación de las etiquetas se emplearon tres metodologías diferentes: relación de aspecto, correlación 2D y algoritmo SURF. Relación de aspecto y correlación se utilizan para detectar diferencias importantes entre el patrón y el sector bajo análisis. Si se supera el límite establecido para ambas metodologías se considera comparación satisfactoria. En cuyo caso se aplica la metodología SURF que si bien es la que determina la correspondencia, es la que más recursos computacionales utiliza. Motivo por el cual la correlación y relación de aspecto son aplicados como filtros iniciales.

La relación de aspecto implementada tiene como objetivo comparar el tamaño (ancho y alto) del patrón y del objeto bajo análisis. Se utiliza debido a que en ciertas situaciones los sectores blancos detectados tienen dimensiones mayores a las etiquetas a etiquetas. La expresión que rige la relación de aspecto es la siguiente:

$$RA = abs\left(\frac{\frac{ptnWidth}{ptnHeight} - \frac{imgWidth}{imgHeight}}{\frac{ptnWidth}{ptnHeight}}\right) \quad (1)$$

donde, ptnWidth y ptnHeight representan el ancho y alto del patrón respectivamente, imgWidth y imgHeight representan el ancho y alto del objeto bajo análisis. Una vez obtenido el resultado, si éste es menor que el umbral de 0.20 (empírico) se considera posible positivo. Si no es así, se descarta el objeto.

Los objetos que cumplen la condición de relación de aspecto fueron comparados nuevamente con el patrón, pero esta vez utilizando el coeficiente de correlación 2D:

$$r = \frac{\sum_m \sum_n (A_{mn} - \bar{A})(B_{mn} - \bar{B})}{\sqrt{(\sum_m \sum_n ((A_{mn} - \bar{A})^2)(\sum_m \sum_n ((B_{mn} - \bar{B})^2))} \quad (2)$$

Donde  $r$  es el coeficiente de correlación,  $A_{mn}$  el pixel  $mn$  del objeto a analizar,  $\bar{A}$  la media de la matriz correspondiente a la imagen del objeto bajo análisis,  $B_{mn}$  el pixel  $mn$  del patrón y  $\bar{B}$  la media de la matriz correspondiente a la imagen patrón.

Si este coeficiente supera el umbral de 0.4 (empírico) se procede a ejecutar la última etapa del algoritmo, en caso contrario se descarta el objeto.

SURF, último algoritmo aplicado, permite obtener una representación detallada de la imagen basada en puntos de interés de la misma. Esta metodología tiene como premisa encontrar características particulares entre dos imágenes como gradientes de orientación de bordes, entre otros. Esto sin importar el escalado, rotación e iluminación, ya que hace hincapié en puntos específicos que representan al objeto. Se observa que la curvatura de la botella no es corregida

en el patrón ni los objetos detectados, esto se debe a que el algoritmo contempla características de la etiqueta, tales como, tipografía y figuras.

El algoritmo SURF consta de seis etapas de procesamiento: aproximación del laplaciano del gaussiano, búsqueda de puntos de interés, eliminación de puntos espurios, obtención de gradientes de orientación, generación de las características SURF [13]. Estas últimas son las coincidencias que existen entre las dos imágenes comparadas. En el algoritmo presentado, si la cantidad de características SURF supera el umbral de 20 (empírico), la imagen analizada es considerada como comparación positiva (Fig. 3).



**Fig. 3.** Resultado SURF - Imagen Patron (Izquierda) - Objeto bajo Analisis (Derecha)

### 3 Resultados y Discusión

A continuación se presentan los resultados obtenidos de la ejecución del algoritmo utilizando los seis patrones mencionados (Tabla 1). Se analizó la Sensibilidad (Capacidad de identificar positivos) y especificidad (Capacidad de rechazo de negativos) del algoritmo. Este análisis es presentado para cada patrón en particular y general, es decir, contemplando todos los casos.

Los resultados de la detección son satisfactorios. En cuanto a la identificación, se observa que la especificidad del algoritmo es alta, con un resultado similar en todos los patrones utilizados. El algoritmo tiene un comportamiento bueno en referencia al rechazo de falsos. En cambio si se analizan los resultados de sensibilidad, se observan valores muy dispares. Estos falsos positivos son aceptados en mayor o menor medida según el patrón utilizado. Éstas diferencias se deben a la similitud que existe en las tipografías de las etiquetas o la baja cantidad de detalles gráficos que presentan los mismos. Por ejemplo, el patrón Marcus contiene la mayor cantidad de detalles gráficos de todos los patrones presentados, debido a eso la sensibilidad obtenida en el algoritmo es del 100%. Contiene los suficientes detalles para diferenciarse de los demás en todas las comparaciones realizadas. En cuanto a Norton Bonarda y Norton clásico, cuentan con etiquetas

muy similares. Especialmente, el logotipo de la marca Norton, que es idéntico en ambas botellas. Esto genera falsos positivos al comparar ambos patrones.

**Table 1.** Resultados Obtenidos

Vino Marca	Resultado	Condicion Verdadera			Sensibilidad	Especificidad
		Positivo	Negativo	Total		
Dadá	Positivo	6	4	10	40%	96,74%
	Negativo	9	119	128		
	Total	15	123	138		
Marcus	Positivo	5	6	11	100%	95,48%
	Negativo	0	127	127		
	Total	5	133	138		
Norton Bonarda	Positivo	12	14	26	54,54%	87,93%
	Negativo	10	102	112		
	Total	22	116	138		
Norton Clásico	Positivo	4	11	15	50,00%	91,53%
	Negativo	4	119	123		
	Total	8	130	138		
San Huberto	Positivo	3	14	17	37,50%	89,23%
	Negativo	5	116	121		
	Total	8	130	138		
Santa Ana	Positivo	8	7	15	61,53%	94,4%
	Negativo	5	118	123		
	Total	13	125	138		
Resultado General	Positivo	38	56	94	53,52%	92,60%
	Negativo	33	701	734		
	Total	71	757	828		

## 4 Conclusiones

Los resultados demuestran que el algoritmo es susceptible a cambios mínimos entre etiquetas diferentes y contempla una tendencia a aumentar su susceptibilidad a medida que se incrementan los detalles en las mismas. En referencia al rechazo de falsos el algoritmo se considera robusto. Como trabajo a futuro se pretenden aplicar otras técnicas como shape context para mejorar las metricas obtenidas.

## Referencias

1. Eduardo Bayro-Corrochano, Jan-Olof Eklundh: Advances in theory and applications of pattern recognition, image processing and computer vision Pattern Recognition Letters 32 (2011) 2143–2144
2. KING-SUN FU, AZRIEL ROSENFELD: Pattern Recognition and Image Processing. IEEE TRANSACTIONS ON COMPUTERS, VOL. C-25, NO. 12, DECEMBER 1976.

3. Amir Atapour Abarghouei, Afshin Ghanizadeh, Saman Sinaie, Siti Mariyam Shamsuddin: A Survey of Pattern Recognition Applications in Cancer Diagnosis. 2009 International Conference of Soft Computing and Pattern Recognition.
4. Ursina Caluori, Klaus Simon: DETEXTIVE optical character recognition with pattern matching on-the-fly Pattern Recognition 48 (2015) 827–836.
5. A Ion, Cosmin Dit, B Marius Otes teanu, C Franz Quint: Scanning Industrial Data Matrix Codes 19th Telecommunications forum TELFOR 2011 Serbia, Belgrade, November 22-24, 2011.
6. Mohammad H. Karimi, Davud Asemani: Surface defect detection in tiling Industries using digital image processing methods: Analysis and evaluation. ISA Transactions 53 (2014) 834–844.
7. Hussin R., Rizon Juhari M., Kang Ng Wei, Ismail R.C., Kamarudin A. Digital Image Processing Techniques for Object Detection From Complex Background Image. International Symposium on Robotics and Intelligent Sensors 2012 (IRIS 2012)
8. Jayashree R. Prasad, Dr. U.V. Kulkarni: Trends in Handwriting Recognition Hird International Conference on Emerging Trends in Engineering and Technology
9. Wenju Zhou, Minrui Fei, Huiyu Zhou, Kang Li: A sparse representation based fast detection method for surface defect detection of bottle caps Neurocomputing 123 (2014) 406–414
10. Faiz M. Hasanuzzaman, YingLi Tian, Qingshan Liu: Identifying Medicine Bottles by Incorporating RFID and Video Analysis. IEEE International Conference on Bioinformatics and Biomedicine Workshops 2011
11. Mu Chien Chou, Regina W.Y. Wang: Displayability: An assessment of differentiation design for the findability of bottle packaging. Displays 33 (2012) 146–156
12. Li-Hong Juang, Ming-Ni Wu, Zhi-Zhong Weng: Object identification using mobile devices Measurement 51 (2014) 100–111
13. Herbert Bay, Andreas Ess, Tinne Tuytelaars, Luc Van Gool: Speeded-Up Robust Features. Computer Vision and Image Understanding 110 (2008) 346–359.